

1 Objetivo

- Através de prática sobre um dataset, este trabalho busca consolidar alguns dos conhecimentos sobre análise de dados apresentados ao longo do semestre.
- A atividade pode ser feita em grupos de até 5 integrantes. Todos devem fazer o upload do relatório.

2 O que entregar no Moodle

- O grupo deve entregar um documento único em formato de relatório (leiaute a sua escolha) com as evidências solicitadas no descritivo das tarefas.

3 Dataset

- O arquivo contém 1 milhão de registros sobre carros no mercado dos estudos unidos. Ele foi escolhido por conta do volume de dados tanto em instâncias quanto em features.
- No Anexo I deste documento contém o descritivo dos atributos.
- O arquivo foi obtido no Kaggle (<https://www.kaggle.com/datasets/metawave/vehicle-price-prediction>).

4 Detalhamento da Atividade

- A atividade consiste em algumas abordagens em análise de dados mostradas na disciplina. A sugestão é que se utilize o Orange Data Mining para tal, mas outras ferramentas podem ser usadas.
- O resultado a ser entregue é um relatório demonstrando as tarefas realizadas com evidências (print de telas, gráficos, etc.).
- Devem ser incluídos também comentários e descritivos sobre a aplicação das técnicas e os resultados obtidos.

5 Tarefas com o Arquivo

5.1 Pré-processamento

- Identifique a existência de "missing values".
- Descreva a técnica utilizada para resolver os casos de dados faltantes.
- Transforme os atributos categóricos em numéricos e explique a técnica utilizada.
- Aplique algum tipo de normalização nos dados transformados.

5.2 Algoritmos de Aprendizado de Máquina.

5.2.1 Regressão Linear Múltipla

- Esta técnica vai demonstrar o grau de importância das features na formação do preço (price) do veículo. Fica a seu critério escolher quais variáveis independentes serão usadas para o estudo.
- Mostre o resultado da regressão: os coeficientes encontrados, R-Quadrado e valor-P de cada feature.

5.2.2 K-means

- Este algoritmo de agrupamento mostrará como os cálculos classificaram as instâncias para formar os grupos. Fica a seu critério o número de grupos resultante. Separe um dos grupos e comente a semelhança entre os veículos.

5.2.3 K-nn

- Escolha um dos veículos e utilize este algoritmo para mostrar os 5 mais parecidos com ele. Depois localize o veículo nos agrupamentos do item anterior e veja se os semelhantes estão no mesmo cluster. Mostre os resultados no relatório.

ANEXO - Descrição dos Atributos do Dataset

id	nome	descrição
1	make	The manufacturer or brand of the vehicle (e.g., Ford, Toyota).
2	model	The specific model of the vehicle (e.g., F-150, Camry).
3	year	The year the vehicle was manufactured.
4	mileage	The total distance the vehicle has been driven, in miles.
5	engine_hp	The horsepower of the vehicle's engine.
6	transmission	The type of transmission (Automatic or Manual).
7	fuel_type	The type of fuel the vehicle uses (e.g., Gasoline, Diesel, Electric).
8	drivetrain	The drive type of the vehicle (e.g., FWD, RWD, AWD).
9	body_type	The style of the vehicle's body (e.g., SUV, Sedan, Pickup Truck).
10	exterior_color	The primary color of the vehicle's exterior.
11	interior_color	The primary color of the vehicle's interior.
12	owner_count	The number of previous owners the vehicle has had.
13	accident_history	The recorded accident history of the vehicle (None, Minor, or Major).
14	seller_type	The type of entity selling the vehicle (Dealer or Private).
15	condition	The overall condition of the vehicle (Excellent, Good, or Fair).
16	trim	The specific trim level of the vehicle model.
17	vehicle_age	The age of the vehicle in years, calculated as Current Year - Year.
18	mileage_per_year	The average number of miles the vehicle was driven per year.
19	brand_popularity	A score representing the popularity of the brand based on its frequency in the dataset.
20	price	The used price of the vehicle in USD.